Classificação de gêneros musicais

Daniel Valentins de Lima

08/07/2020

```
library(tidyverse)
library(janitor)
library(tidymodels)
library(textrecipes)
library(tidytext)

theme_set(theme_minimal())
```

Importando os bancos

```
letras_bossa_nova <- read_csv("./letras_mus_br_bossa-nova.csv") %>%
  mutate(genero = "bossa_nova")

letras_mpb <- read_csv("./letras_mus_br_mpb.csv") %>%
  mutate(genero = "mpb")

letras <- letras_bossa_nova %>%
  bind_rows(letras_mpb) %>%
  select(-titulo, -artista) %>%
  mutate(genero = as_factor(genero))
```

${\bf Modelagem}$

Bancos de treino e teste

```
set.seed(0099)
letras_split <- initial_split(letras)

letras_training <- training(letras_split)
letras_testing <- testing(letras_split)</pre>
```


Processamento dos dados

```
letras_tokens <- letras_training %>%
  unnest_tokens(tokens, letras)
letras_tokens
```

```
## # A tibble: 237,008 x 3
##
         X1 genero
                        tokens
##
      <dbl> <fct>
                        <chr>
##
   1
          O bossa_nova era
##
    2
          0 bossa_nova uma
##
    3
          0 bossa_nova casa
##
          O bossa_nova muito
##
   5
          O bossa_nova engraçada
##
          O bossa_nova não
##
   7
          0 bossa_nova tinha
##
          0 bossa_nova teto
##
          O bossa_nova não
## 10
          0 bossa_nova tinha
## # ... with 236,998 more rows
```

```
letras_tokens %>%
count(X1) %>%
ggplot(aes(n)) +
geom_histogram(binwidth = 10) +
labs(title = "Distribuição do número de palavras em cada música")
```

Distribuição do número de palavras em cada música



```
rec_spec <- recipe(genero ~ letras, data = letras_training) %>%
  step_tokenize(letras) %>%
  step_stopwords(letras, language = "pt") %>%
  step_tokenfilter(letras, max_tokens = tune()) %>%
  step_tf(letras, weight_scheme = "binary")
```

Modelo SVM

```
mod_spec <- svm_rbf(cost = tune(), rbf_sigma = tune()) %>%
    set_engine("kernlab") %>%
    set_mode("classification")

set.seed(0099)
letras_folds <- vfold_cv(letras_training, v = 5)

letras_wf <- workflow() %>%
    add_recipe(rec_spec) %>%
    add_model(mod_spec)

tune_res <- tune_grid(
    letras_wf,
    resamples = letras_folds,
    grid = 25,
    control = control_grid(verbose = T)
)</pre>
```


Métricas

```
show_best(tune_res, "accuracy")
## # A tibble: 5 x 8
      cost rbf_sigma max_tokens .metric .estimator mean
                                                       n std_err
##
     <dbl>
             <dbl>
                       <int> <chr>
                                     <chr>
                                              <dbl> <int>
                                                           <dbl>
                         664 accuracy binary
## 1 27.1
           0.0638
                                               0.719
                                                       5 0.0166
## 2 0.980 0.00257
                                                       5 0.00720
                         550 accuracy binary 0.691
## 3 0.209 0.0246
                         99 accuracy binary
                                             0.645
                                                       5 0.0119
## 4 3.16
            0.928
                         815 accuracy binary
                                             0.583
                                                      5 0.0129
## 5 0.507 0.00151
                         368 accuracy binary
                                             0.547
                                                        5 0.0385
```

Acurácia


```
collect_metrics(tune_res) %>%
  filter(.metric == "accuracy") %>%
  ggplot(aes(cost, rbf_sigma, size = max_tokens, color = mean)) +
  geom_point() +
  scale_y_log10() +
```

```
scale_x_log10() +
scale_color_viridis_c()
```



Curva ROC

```
collect_metrics(tune_res) %>%
  filter(.metric == "roc_auc") %>%
  ggplot(aes(cost, rbf_sigma, size = max_tokens, color = mean)) +
  geom_point() +
  scale_y_log10() +
  scale_x_log10() +
  scale_color_viridis_c()
```



```
best_accuracy <- select_best(tune_res, "accuracy")

final_wf <- finalize_workflow(
  letras_wf,
  best_accuracy
)

final_wf</pre>
```

```
## cost = 27.1427682985615
## rbf_sigma = 0.063797168553877
##
## Computational engine: kernlab
```

Finalizando o modelo

```
final_res <- final_wf %>%
last_fit(letras_split)
final_res %>%
 collect metrics()
## # A tibble: 2 x 3
## .metric .estimator .estimate
## <chr>
            <chr>
                         <dbl>
## 1 accuracy binary
                          0.712
## 2 roc_auc binary
                          0.741
final_res %>%
 unnest(.predictions)
## # A tibble: 500 x 10
##
     splits id .metrics .notes .pred_bossa_nova .pred_mpb .row .pred_class
##
                                         <dbl>
                                                   <dbl> <int> <fct>
     <list> <chr> <list> <list>
                                                   0.118 7 bossa_nova
## 1 <spli~ trai~ <tibble~ <tibb~
                                          0.882
                                                   0.712 9 mpb
## 2 <spli~ trai~ <tibble~ <tibb~
                                        0.288
                                                  0.882
## 3 <spli~ trai~ <tibble~ <tibb~</pre>
## 4 <spli~ trai~ <tibble~ <tibb~
                                        0.299
                                                0.701 15 mpb
## 5 <spli~ trai~ <tibble~ <tibb~
                                        0.436
                                                 0.564 19 mpb
## 6 <spli~ trai~ <tibble~ <tibb~
                                                  0.127 20 bossa_nova
                                        0.873
                                                   0.692 26 mpb
## 7 <spli~ trai~ <tibble~ <tibb~</pre>
                                         0.308
## 8 <spli~ trai~ <tibble~ <tibb~
                                         0.882
                                                  0.118 29 bossa_nova
                                                   0.467 31 bossa_nova
## 9 <spli~ trai~ <tibble~ <tibb~
                                         0.533
                                                   0.244
## 10 <spli~ trai~ <tibble~ <tibb~
                                          0.756
                                                           36 bossa_nova
## # ... with 490 more rows, and 2 more variables: genero <fct>, .workflow <list>
```

Matriz de confusão

```
final_res %>%
  unnest(.predictions) %>%
  conf_mat(truth = genero, .pred_class) %>%
  autoplot(type = "heatmap") +
  labs(title = "Matriz de confusão: Classificação de gênero musical")
```



